模型管理

需求背景

痛点	预期解法
模型上架缓慢，依赖研发接入	运维侧仅接入供应商，模型上架由产品完成
模型路由缺失，不同企业应用未路由专属的apikey	运维侧基于不同供应商分配API KEY，基于应用id的企业，完成路由
模型原厂、模型云厂商模型参数配置不同，较多参数仍需要通过extrabody配置，其次流式输出、Json输出仍为研发硬编码	需统一Proxy服务维护不同供应商参数差异，下架阿里云、火山云的无效参数seed（随机种子），增加Json输出、流式输出配置，同时为后续MCP注入做基础
模型在提示词后台、alpha环境、线上环境效果不一致，上下架模型缺乏测试，缺乏管理关联关系	增加模型测试功能，测试支持的参数，其次增加关联应用节点统计
模型下架关联影响较难定位	提供可视化的页面

交互原型

🔗 模型管理

模型接入分工

1）Max侧，提供不同企业（手回、手回保险代理、小雨伞）、不同厂商的API KEY及Base URL

2）Erick、Pete侧，屏蔽不同厂商差异，如MCP、JSON、深度思考、流式输出等；并提供价格、能力支持

3）Infra侧，读取可用供应商信息，添加模型id，及模型名称。

基于模型id，渲染价格、能力支持、默认配置信息。

产品侧基于默认信息微调参数、并进行测试验证

需求详情

1、模型管理列表

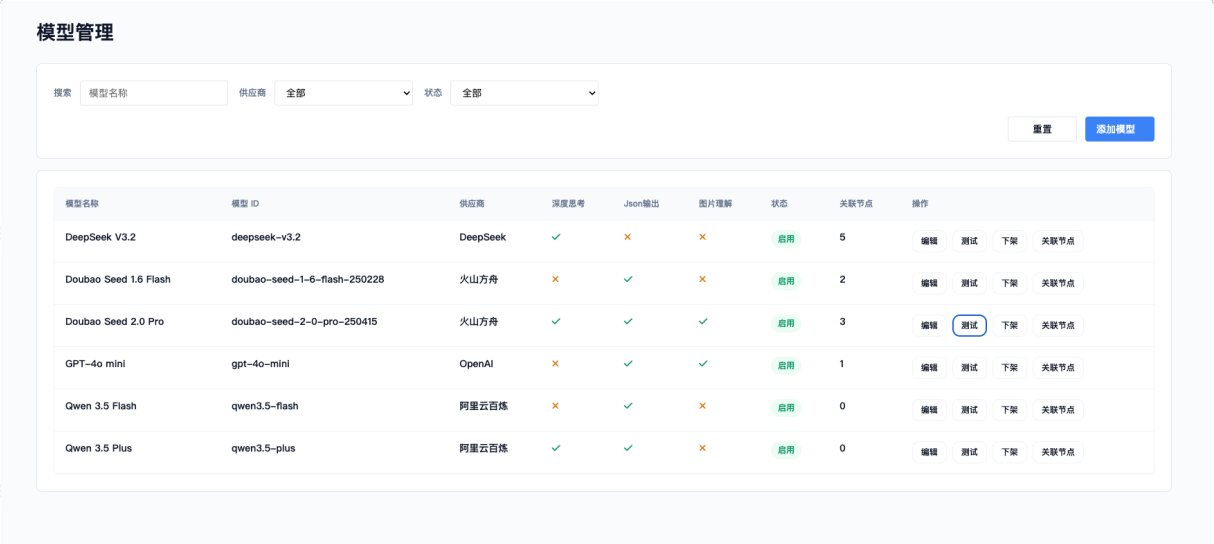

1）筛选项

搜索，文本框，支持模糊搜索模型名称

供应商，下拉框，默认全部，枚举值由实际配置模型供应商，目前明确的是阿里云、火山引擎

状态，下拉框，默认是启动，枚举值 全部、启动、下架

2）列表

- 模型名称、id、供应商、深度思考、json输出、图片、文件，读取自该行配置
- 状态，基于当前模型启用、关闭状态统计
- 关联节点，基于应用管理-模型节点-模型统计
- 列表操作，见下文

2、 添加/编辑模型

点击添加模型，触发模型弹窗

1）基础信息

- 供应商，枚举值来自erick老师proxy服务，不支持新增
- 模型ID，基于供应商提供的模型ID进行输入
- 模型名称，自定义配置

2）模型价格

区分统一、或者梯度，决定思考、非思考的计费方式，如果为统一，思考和非思考全部都是都为统一计价。

区分思考，非思考，定价

3）能力支持

区分输入、输出

输入：文本理解（默认勾选）、图片理解、文件理解

输出：基于厂商支持情况，渲染深度思考（on/off)、深度思考(auto)、流式输出、Json格式化、

其中，深度思考、Json格式、流式输出的勾选情况会影响下方的模型默认配置，深度思考的两种模式为互斥选项

其中，深度思考、Json格式化、图片理解，会影响测试的内容。

4）默认配置

影响提示词、应用管理，选中模型时的默认配置

- 默认具备温度、Maxtoken、超时、Extrabody字段
- 能力支持开启深度思考auto，默认配置渲染思考模型配置，枚举值：关闭、开启、自动
- 能力支持开启深度思考on、off，默认配置渲染思考模型配置，枚举值：关闭、开启
- 能力支持开启流式输出，默认配置渲染流式输出配置，枚举值：关闭、开启
- 能力支持开启Json格式化，默认配置渲染Json格式化配置，枚举值：关闭、开启

添加模型后，默认为下架状态

3、测试

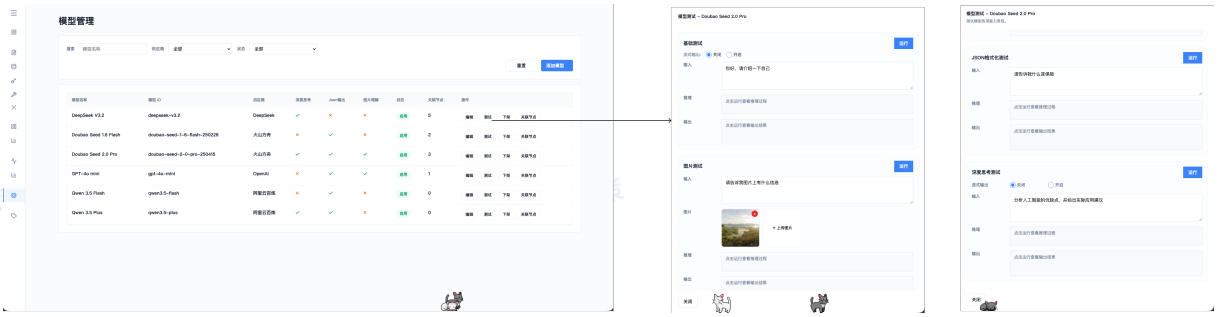

点击测试，触发测试弹窗

1）测试范围

默认具备基础测试+流式输出，图片、文件、Json、深度思考测试范围基于模型配置的能力支持渲染。

2）基准测试

- 默认关闭流式输出，开启后会逐字输出推理、输出效果
- 输入= user prompt，支持编辑
- 点击运行按钮发起请求，注意未开启深度思考，也可能会思考，所以放置推理框区域。点击运行按钮，推理、输出框基于运行结果渲染内容

3）图片测试

默认具备图片，图片后续由产品提供。

支持删除图片，支持上传多张图片

4）文件测试

默认具备文件，文件后续由产品提供。
支持删除文件，支持上传多个文件

文件方案初步考虑业务集成mcp进行测试，此项能力作为基准能力

5）JSON格式化

API参数示例 {"response_format ":{"type": "json_object"}}

6）深度思考测试

默认关闭流式输出，开启后会逐字输出推理、输出效果

3、启用/下架

1）模型状态和按钮具备映射关系，下架状态->只允许启用，启用状态只允许下架

2）下架时触发二次确认弹窗，明确模型关联应用管理中模型节点的数量。

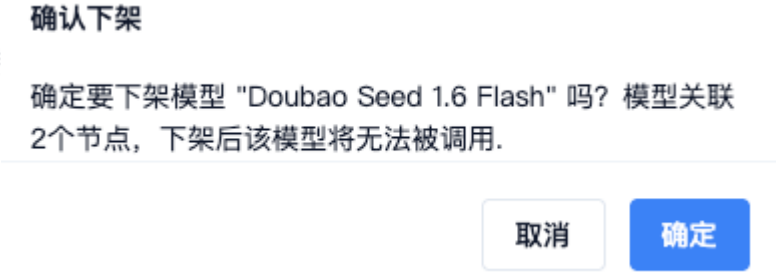

4、 关联节点

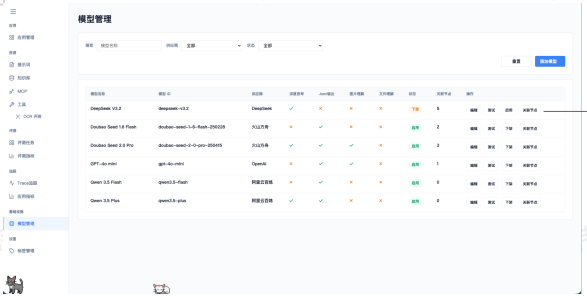

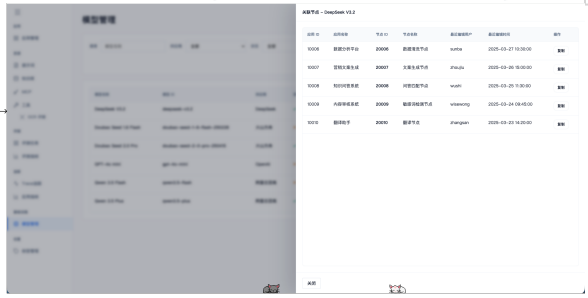

点击模型关联节点，触发关联节点浮层

1）须迁移模型管理中模型配置初始化数据后具备关联节点能力

2）关联节点数据统计：应用管理-模型节点-选中的模型id=当前模型id的总数

3）表格数据展示，节点对应应用id、应用名称、节点id、节点名称、最近更新角色、最近更新时间

4）点击复制输出信息

- 节点ID: 20006
- 应用ID: 10006
- 应用名称: 数据分析平台
- 节点名称: 数据清洗节点
- 最近编辑用户: sunba
- 最近编辑时间: 2025-03-27 10:30:00