PRD-评测体系

1. 文档信息

项目	内容
文档版本	v1.0
最后更新	2025-02-02
产品负责人	wisewong

2. 需求背景

2.1 现状痛点

痛点	详细描述
评测维度单一	目前 AI 应用评测仅基于提示词（Prompt）维度，而非端到端评测。实际上用户使用的是完整应用，提示词只是应用的子集。
缺乏全局可视	当前评测提示词部分缺乏全局可视机制，需要逐条点击进入查看，且没有输入-期望输出-实际输出的对比功能。
调试与评测脱节	目前调试是与评测集脱离的，缺乏体验友好的质检体系，无法系统性地评估应用效果。
环境隔离问题	缺乏跨环境的评测集同步机制，不同环境（dev/alpha/admin）的评测数据无法共享。

2.2 核心目标

端到端评测：从应用层面进行完整链路评测，而非仅关注提示词
全局可视化：在一个页面查看输入、期望输出、实际输出、质检结果
质检闭环：建立完善的质检机制，支持人工标注与评分
效率提升：支持批量运行、批量标注、文件导入，提升评测效率

3. 术语定义

术语	定义
评测集	一组测试用例的集合，用于评估 AI 应用的效果
用例	单个测试样本，包含输入变量、期望输出
评测任务	对评测集进行批量运行的执行实例
输入配置	应用定义的输入变量及其类型配置
期望输出	用例中定义的标准答案（reference_output）
实际输出	AI 应用运行后返回的真实结果（output）

4. 需求范围

4.1 本期范围

应用管理 – 输入配置管理
评测集管理 – 列表、创建、详情、用例管理
评测任务 – 新建任务、任务执行、结果展示

质检体系 - 单条标注、批量标注、质检统计
文件导入 - CSV/Excel 批量导入用例
环境同步 - 跨环境评测集同步

4.2 不在本期范围

提示词级别的细粒度评测
自动化评估器配置（需要人工质检）
评测报告导出（PDF/Word）
历史版本对比

5. 需求详情

5.1 应用管理 – 输入配置

5.1.1 输入配置 – 列表页

【原型图 – 应用输入配置】

字段	说明
中文名称	变量的中文展示名，如"用户问题"
英文名称	变量的英文标识，如 query
变量类型	text（文本）、file（文件）、image（图片）
最近更新人	最后修改配置的用户
最近更新时间	最后修改时间
操作	编辑、删除

5.1.2 输入配置 – 添加/编辑变量

配置项	类型	必填	说明
中文名称	文本框	是	展示用中文名
英文名称	文本框	是	代码使用的变量名，英文+下划线
变量类型	下拉框	是	text/file/image
测试 API 类型	单选框	是	AO/HTTP
测试 API 地址	输入框	是	基于 AO 和 HTTP 渲染 AO：请输入 AO 服务名 HTTP：请输入 API 地址

5.1.3 业务规则

变量同步机制：

应用输入配置添加变量后，关联的评测集自动渲染该字段；

应用删除变量后，评测集中该字段同步删除（历史数据保留但不展示），除非有同名变量再次被配置；

修改变量名称后，评测集等同于新增一个变量

新增变量后，评测集同步新增变量

变量类型说明：text（纯文本输入，支持多行）、file（文件上传，支持 pdf、doc、docx 等）、image（图片上传，支持 png、jpg、jpeg）

其中 file 和 image 为注数组

5.2 评测集

5.2.1 评测集列表页

操作路径：评测 > 评测集

【原型图 - 评测集列表】

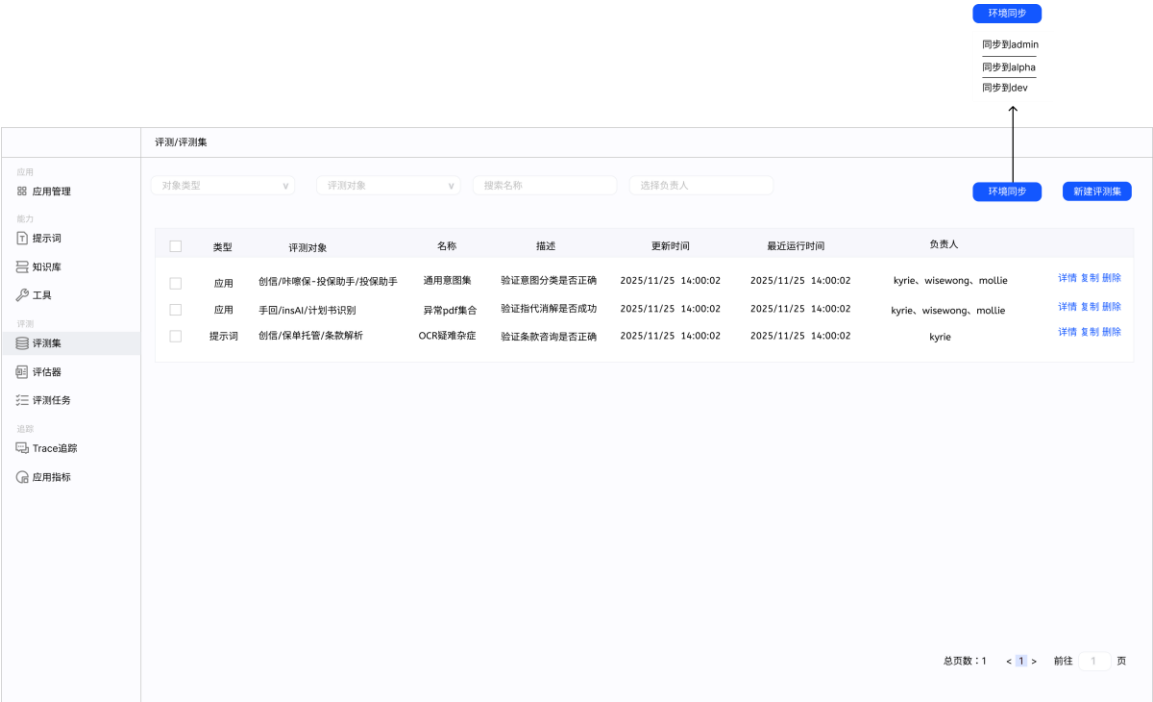

筛选项

筛选项	类型	默认值	说明
对象类型	下拉框	全部	全部/应用/提示词
评测对象	下拉框	全部	企业/项目/应用层级，关联应用管理
名称	搜索框	-	支持模糊搜索评测集名称
负责人	搜索框	-	支持模糊搜索负责人用户名

列表字段

字段	说明
类型	应用 / 提示词
评测对象	如：创信/咔嚓保-投保助手/投保助手

名称	评测集名称
描述	评测集描述
更新时间	评测集或内容最后更新时间
最近运行时间	最后一次评测任务运行时间
负责人	可多人，逗号分隔

操作说明

操作	说明
详情	点击进入评测集详情页
复制	复制一条新记录，名称后加"_副本"，如：123 → 123_副本
删除	触发二次确认弹窗，确认后删除

5.2.2 新建评测集

【原型图 – 创建评测集弹窗】

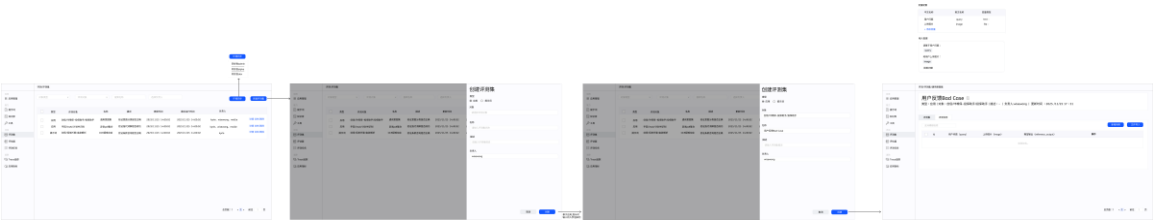

配置项	类型	必填	说明
类型	单选	是	应用 / 提示词
对象	层级下拉框	是	复用应用管理的企业/项目/应用层级
名称	文本框	是	评测集名称
描述	文本框	否	评测集描述说明
负责人	文本框	是	创建人默认为负责人，多输入使用逗号分隔

5.2.3 编辑评测集

点击触发编辑弹窗，支持编辑所有内容。

如果涉及编辑类型、对象，在保存时需要触发二次确认弹窗

弹窗文案：切换类型及对象，将删除所有用例及数据，是否确认切换

按钮：确认，取消

5.2.4 评测集详情页 - 评测集 Tab

【原型图 - 评测集详情-评测集 Tab】

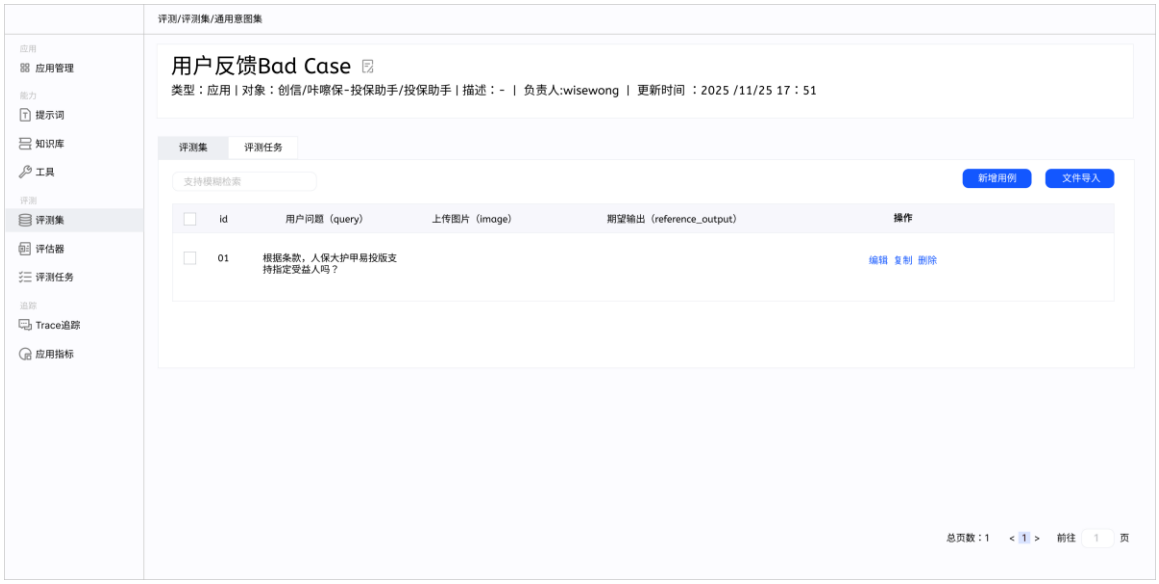

页面结构：

顶部信息区：评测集名称、类型、对象、描述、负责人、更新时间
Tab 切换：评测集 / 评测任务

字段	说明
id	用例序号
输入变量	由应用输入配置渲染的动态字段（如：用户问题、上传图片）
期望输出	每个用例默认具备的期望输出（reference_output）

5.2.5 新增用例

【原型图 - 新增用例弹窗】

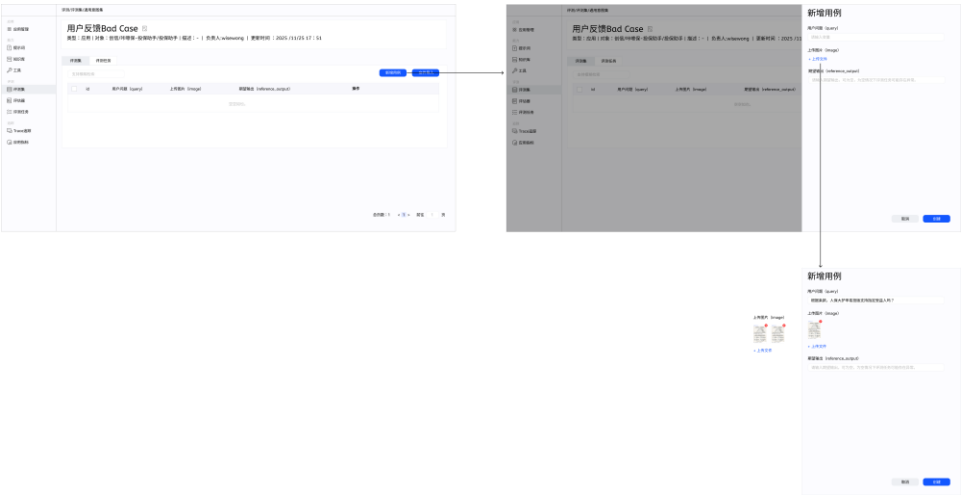

配置项	类型	必填	说明
用户问题（query）	文本域	否	根据输入配置动态渲染
上传图片（image）	文件上传	否	支持多图片上传，可删除
期望输出（reference_output）	文本域	否	可为空，为空时评测任务可能存在异常

5.2.6 编辑用例

【原型图 – 编辑用例弹窗】

与新增用例字段一致，预填充当前用例数据，操作按钮：取消 / 保存

5.2.7 文件导入

【原型图 – 文件导入弹窗】

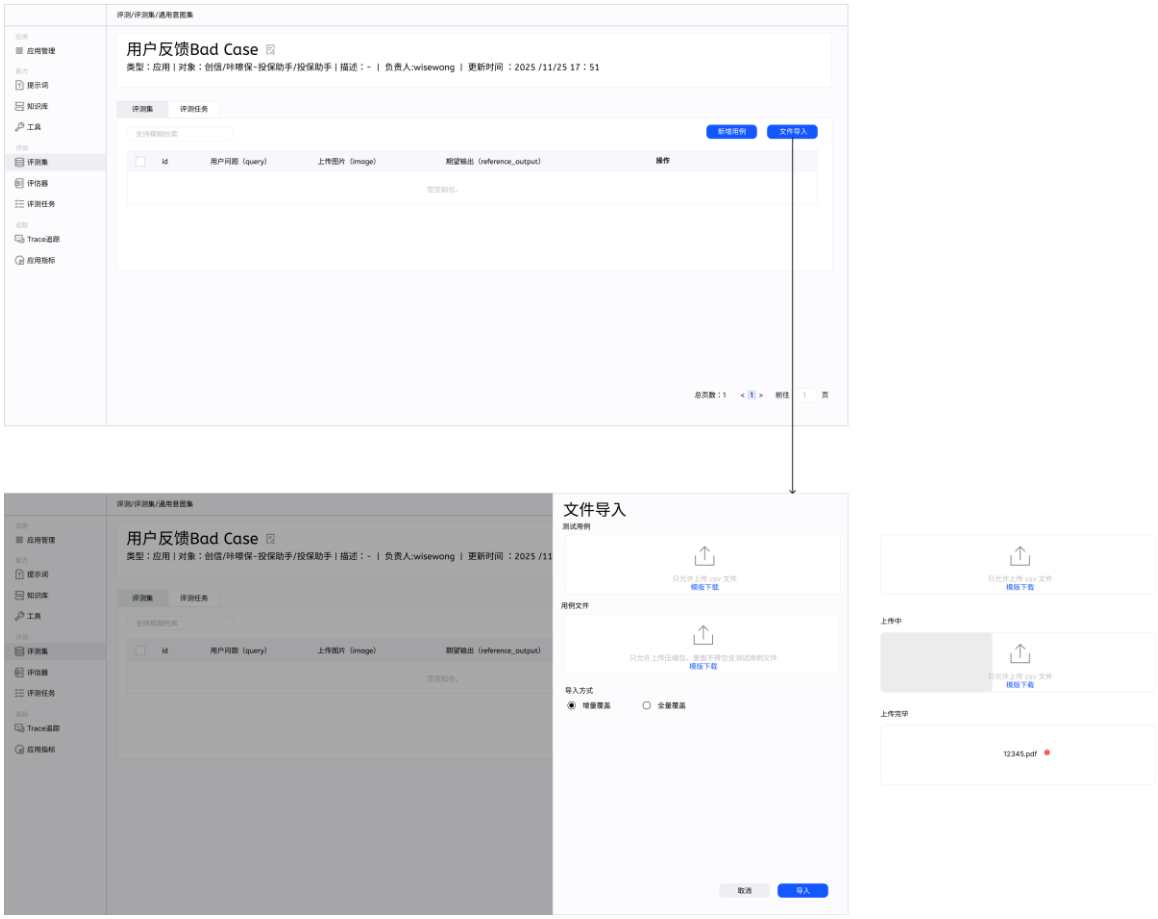

弹窗标题：文件导入

导入区域：

测试用例：只允许上传 csv 文件

用例文件：只允许上传压缩包

导入方式：

增量覆盖（默认）：追加新数据，已有数据不覆盖
全量覆盖：清空现有用例，全部替换为导入数据

用例文件格式

- csv 文件：

1、行列一致

2、首行为变量中文名称

3、第二行为变量英文名称

4、第三行为变量类（text ， file，img），

如为 file 类型，须填写文件名全称，如 xxx.pdf,xxx.png

test_data.csv

- zip、rar 文件：

1、完成解压缩

2、基于 csv，file 类型，检索变量值的文件

3、将文件上传，关联至用例
模板文件.zip

5.3 评测任务

5.3.1 评测任务 Tab

【原型图 - 评测集详情-评测任务 Tab】

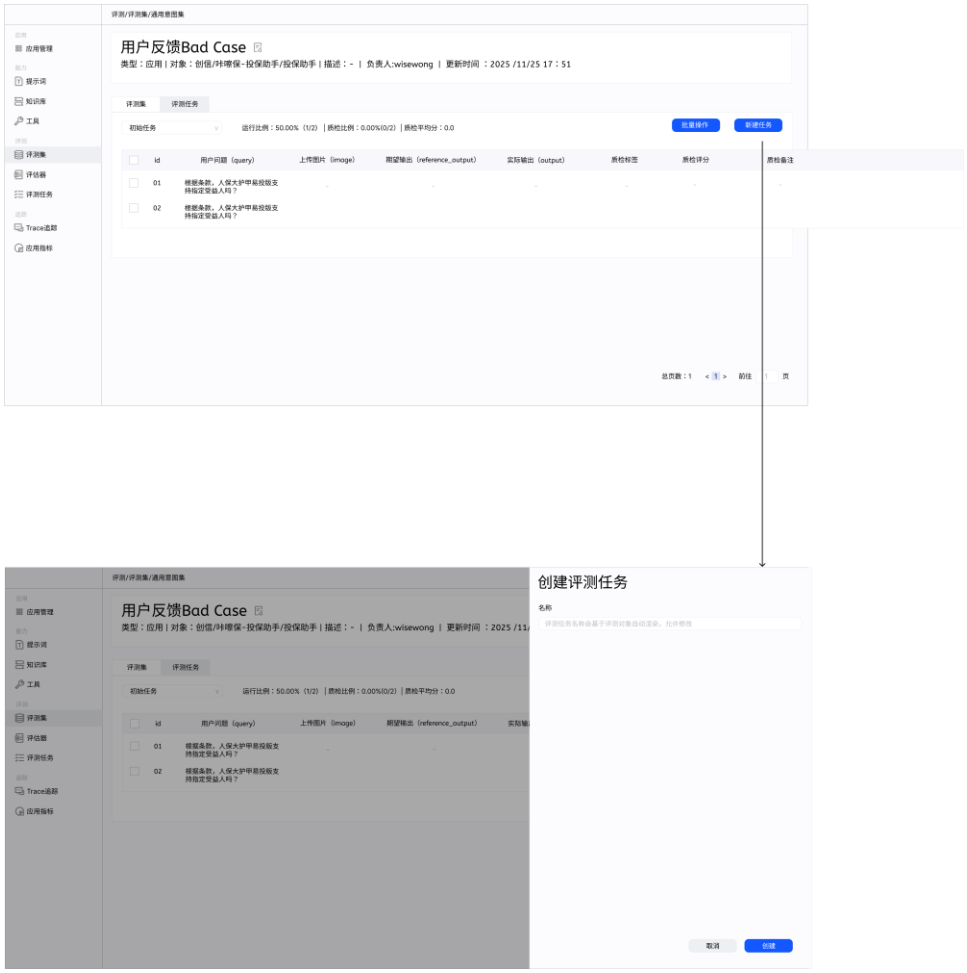

页面结构：

任务统计区：运行比例、质检比例、质检平均分
任务选择器：切换不同评测任务
操作按钮：批量操作、新建任务
结果列表：展示用例执行结果

统计指标说明

指标	说明
运行比例	已运行用例数 / 总用例数，如：50.00%(1/2)
质检比例	已质检用例数 / 运行用例数，如：0.00%(0/2)
质检平均分	所有质检评分的平均值，如：0.0

5.3.2 任务列表字段

字段	说明
id	用例序号

用户问题（query）	输入内容
上传图片（image）	输入图片，hover 可预览
期望输出（reference_output）	标准答案
实际输出（output）	AI 应用返回的实际结果
质检标签	人工标注的标签
质检评分	人工评分，0-5 分
质检备注	质检人员的备注说明
最近运行时间	最近一次运行成功后更新时间

复用 Trace 追踪质检逻辑

5.3.3 任务操作

【原型图 - 任务操作菜单】

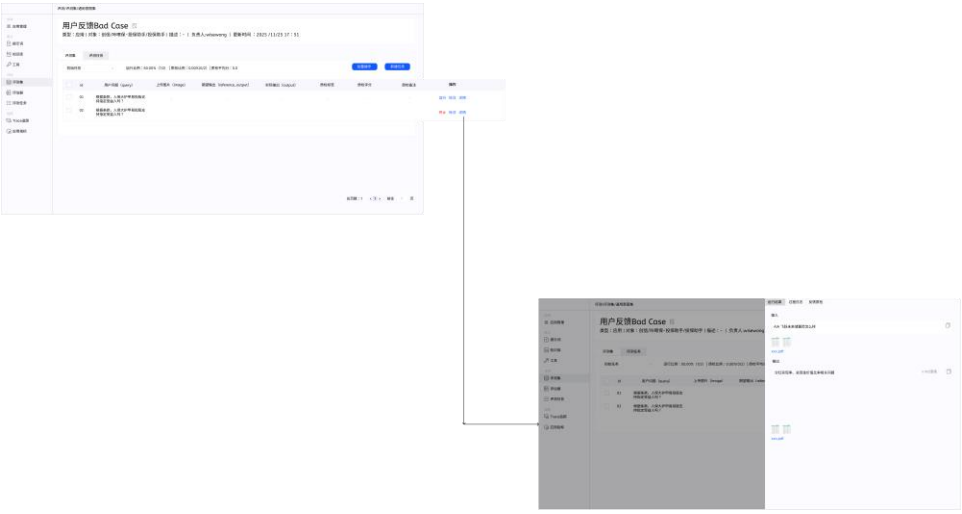

操作	状态	说明
运行	未运行/失败时显示	单独运行该用例
终止	运行中时显示	终止该用例的执行
标注	运行完成后显示	打开标注弹窗进行质检，复用 Trace 追踪逻辑
详情	始终显示	查看完整的输入、输出、过程日志，复用 Trace 追踪逻辑

5.3.4 新建评测任务

【原型图 - 创建评测任务弹窗】

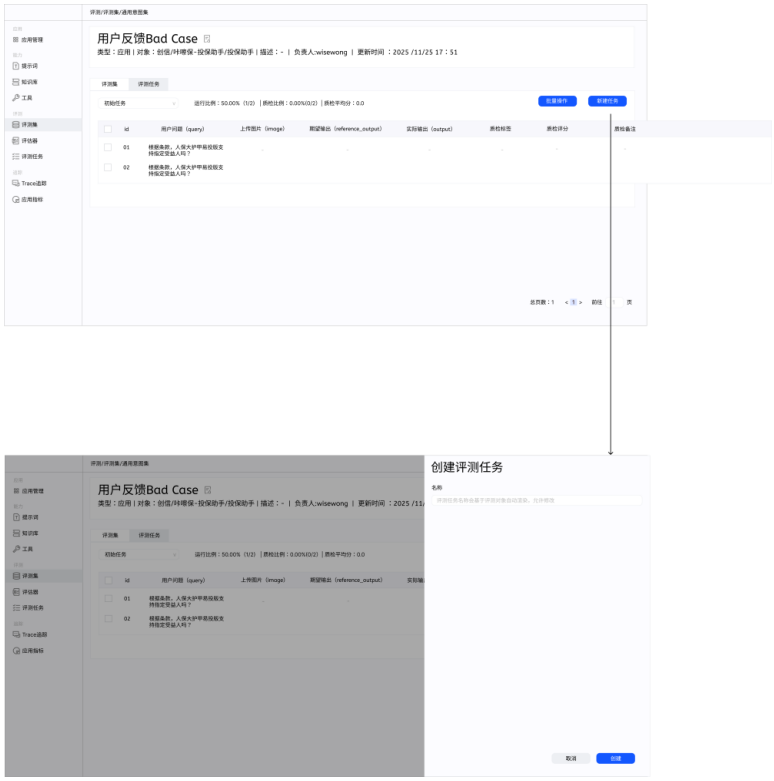

弹窗标题：创建评测任务

配置项：

配置项	类型	必填	说明
名称	文本框	是	用户配置，允许修改

创建后逻辑：

创建评测任务记录，左上角下拉框可筛选。

5.4 质检体系

5.4.1 添加标注（单条）

【原型图 – 添加标注弹窗】

弹窗标题：添加标注

配置项	类型	必填	说明
分值	数字输入	否	0-5 分
备注	文本域	否	质检备注说明
标签	标签选择器	否	支持搜索或选择已有标签，可多选

5.4.2 批量标注

【原型图 – 批量操作与批量标注】

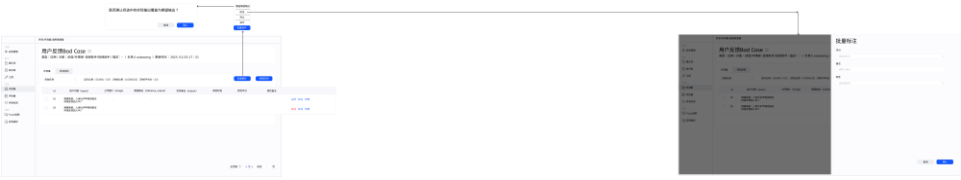

触发方式：

列表勾选多个用例，点击"批量操作"按钮，选择"批量标注"

配置项与单条标注一致

5.4.3 批量操作菜单

操作项	说明
批量运行	批量运行选中的用例
批量标注	批量添加质检标注
终止	批量终止运行中的用例
覆盖期望输出	将选中的实际输出覆盖为期望输出（需二次确认）

5.5 环境同步

【原型图 – 环境同步下拉菜单】

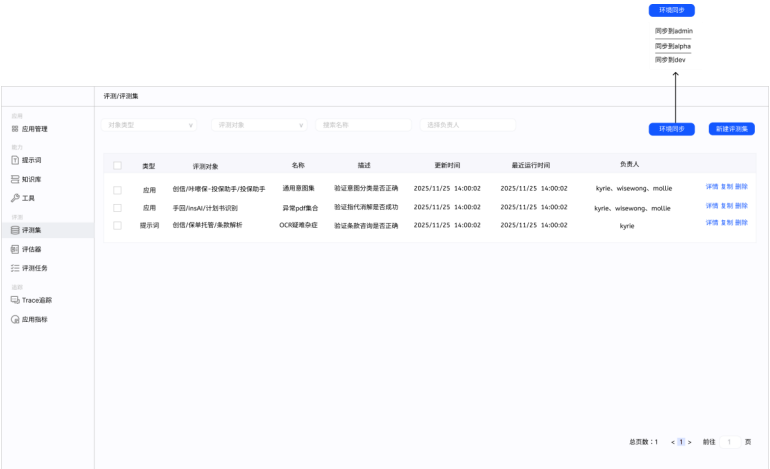

5.5.1 同步规则

规则	说明
权限控制	仅管理员或评测集负责人可执行同步
数据范围	同步评测集基本信息 + 所有用例数据
同步策略	1、只能同步自身为负责人的评测集 2、同步时校验评测集名称 -已存在同名评测集时，提示"是否确认覆盖评测集" -不存在时，直接覆盖
任务不同步	评测任务记录不跨环境同步

5.6 Trace 追踪字段标识

trace 追踪 trace 增加字段，标识评测数据和线上数据；

Trace 追踪默认选中线上数据

字段名称：Trace 类型，字段值：评测、线上

5.7 历史系统参考

【原型图 – 旧版测试集管理（参考）】

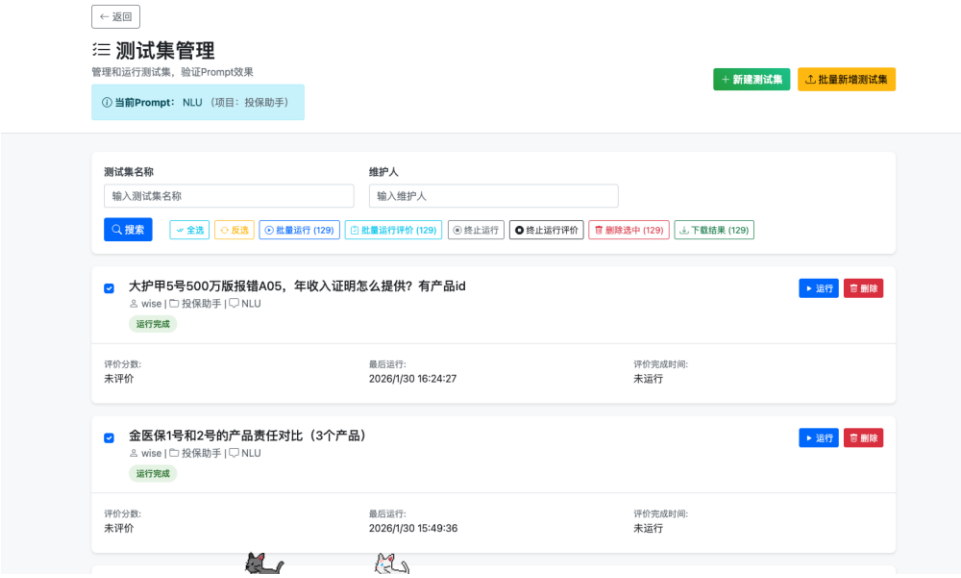

旧版系统功能参考：

管理和运行测试集，验证 Prompt 效果
支持批量运行、批量评价、终止运行
展示评价分数、运行时间等统计信息
[手回科技集团零信任网关]